

Análisis comparativo de modelos de aprendizaje de máquina para la detección de malaria en imágenes microscópicas de células sanguíneas.

Juan José Garzón Mejía y Juan José Barrientos Salazar

*Systems Engineering 504, Faculty of Engineering, Department of System Engineering
Universidad de Antioquia (UdeA), Calle 50 No. 73–21, 050034, Medellín, Colombia
juan.garzonm@udea.edu.co, juanj.barrientos@udea.edu.co*

Abstract—Este es el abstract del proyecto, se generará cuando se termine el último entregable junto con la propuesta del mismo y los resultados obtenidos.

Index Terms—Aprendizaje de máquina, clasificación binaria, malaria, redes neuronales convolucionales, visión por computador.

I. INTRODUCCIÓN Y DESCRIPCIÓN DEL PROBLEMA

LA malaria constituye una de las enfermedades infecciosas de mayor impacto en la salud pública global, siendo causada por parásitos del género *Plasmodium* y transmitida principalmente mediante la picadura del mosquito *Anopheles*. A pesar de la existencia de protocolos diagnósticos consolidados, el análisis microscópico de frotis sanguíneos permanece como el estándar de oro, especialmente en entornos de recursos limitados donde se requiere un balance entre bajo costo y efectividad [1]. No obstante, la fiabilidad de este procedimiento se ve condicionada por la pericia del observador, la fatiga diagnóstica y la variabilidad inter-especialista, factores que han impulsado la investigación de soluciones basadas en el aprendizaje de máquina para automatizar la identificación de eritrocitos infectados [2], [3].

En el presente proyecto se aborda el desarrollo de un sistema de detección de malaria fundamentado en el procesamiento de imágenes digitales de células sanguíneas. El modelo se enmarca en el paradigma de aprendizaje supervisado, formulado específicamente como una tarea de clasificación binaria. Para este propósito, se utiliza el *Malaria Cell Images Dataset* [4], un corpus público recolectado por el *National Institutes of Health* (NIH). Este conjunto consta de 27.558 imágenes de frotis de sangre delgada, distribuidas equitativamente entre células parasitadas y sanas. En este contexto, las variables predictoras corresponden a matrices de píxeles (variables numéricas discretas con intensidades de 0 a 255) que encapsulan la morfología y textura celular. Es fundamental precisar que, aunque estas matrices de píxeles constituyen las características de entrada, la extracción de los rasgos visuales definitivos no se hará manualmente, sino que se realizará de manera automatizada a través de Redes Neuronales Convolucionales (CNN), delegando al modelo el aprendizaje de las

jerarquías visuales. Por su parte, la variable objetivo es de naturaleza categórica binaria (parasitada o no parasitada).

Desde la perspectiva del análisis exploratorio de datos, el dataset permite evaluar dimensiones críticas como la resolución de las imágenes y la variabilidad en las condiciones de adquisición (iluminación, contraste y nitidez). Dado que el problema carece de un componente temporal, el análisis se centra en la extracción de características espaciales. El manejo del ruido visual derivado de la tinción de las muestras es un reto inherente al dominio de la visión por computador aplicada a la medicina [1], resultando determinante para garantizar la robustez del modelo frente a variaciones biológicas en entornos clínicos.

La integración de modelos de aprendizaje profundo en este contexto ofrece una oportunidad para optimizar el flujo de trabajo en los laboratorios de hematología, actuando como un sistema de apoyo a la toma de decisiones que prioriza casos críticos y reduce la carga operativa [5]. Académicamente, este problema facilita el estudio comparativo abarcando desde la ingeniería de características manual hasta la extracción automática mediante arquitecturas profundas [6].

La metodología propuesta permite contrastar el desempeño de modelos clásicos —como Support Vector Machines (SVM) o Random Forest— frente a Redes Neuronales Convolucionales (CNN) que procesan la información de forma *end-to-end*. Diversas investigaciones han demostrado que el uso de arquitecturas como ResNet o MobileNet puede ofrecer una ventaja significativa en la precisión diagnóstica bajo estas condiciones [7]. Finalmente, la estrategia experimental contempla la partición estratificada de los datos y la implementación de técnicas de aumento de datos (*data augmentation*) para mitigar el sobreajuste. Todo el desarrollo técnico, los scripts de preprocesamiento y la configuración de los modelos se encuentran disponibles en el repositorio oficial: <https://github.com/JuanCOD001116/Malaria-Detection-DeepLearning>.

II. TRABAJO RELACIONADO

La revisión de la literatura especializada permite establecer un marco de referencia sobre cómo la comunidad científica ha abordado esta tarea bajo el paradigma del aprendizaje supervisado. En cuanto a las técnicas, se evidencia una evolución desde métodos clásicos hacia arquitecturas profundas. Inicial-

mente, Rajaraman *et al.* [8] exploraron el uso de CNNs pre-entrenadas (como AlexNet y ResNet) como extractores de características fijos para alimentar clasificadores, validando su enfoque en el conjunto de datos del NIH. Utilizando una metodología de partición de datos estándar y métricas de exactitud y AUC, reportaron que estos modelos superan el 95% de precisión, estableciendo que las redes profundas son superiores a la ingeniería de rasgos manual. En una línea similar, Rojas Tocora [2] analizó la clasificación de los cuatro parásitos de malaria humana empleando arquitecturas de aprendizaje profundo. Su investigación destaca por un análisis exhaustivo de hiperparámetros, donde demostró que al reducir el *min-batchsize* de 100 a 5, el modelo mejoró radicalmente su curva de aprendizaje, logrando una clasificación más precisa de las muestras infectadas.

Por otro lado, Segovia *et al.* [3] validaron la eficacia de las CNNs en el diagnóstico, enfocándose en la capacidad de estas redes para detectar patrones sutiles del parásito *Plasmodium*. Respecto a la metodología de validación, Ferreras Extremo *et al.* [9] propusieron un sistema de ayuda a la decisión basado en un modelo de conjunto (*ensemble*) creado a partir de arquitecturas EfficientNet. Su validación fue especialmente rigurosa, empleando un proceso de validación cruzada de 10 iteraciones (*10-fold cross-validation*). Sus métricas incluyeron Accuracy (98,29%), Sensibilidad (98,82%), Precisión (97,74%), F1-score (98,28%) y un AUC de 99,76%, demostrando que la combinación de modelos base mediante validación cruzada reduce significativamente el error de generalización.

En términos de eficiencia computacional, Meza-Bautista *et al.* [7] realizaron un estudio comparativo supervisado entre ResNet-50V2, MobileNetV2 e EfficientNetB0. Utilizando una metodología de evaluación basada en particiones de entrenamiento y prueba, midieron el Accuracy, Recall y F1-score. Sus resultados indicaron que EfficientNetB0 ofrece el mejor rendimiento global para sistemas con alta capacidad de procesamiento, mientras que MobileNetV2 resultó ideal para dispositivos móviles o con restricciones de hardware, manteniendo niveles de precisión competitivos para su despliegue en punto de atención.

La robustez clínica también ha sido un eje central. Sora-Cardenas *et al.* [1] integraron un paso previo de evaluación de calidad de la tinción antes de la clasificación supervisada, logrando precisiones cercanas al 98% y demostrando que la calidad de la entrada es crítica para el éxito de la CNN. Finalmente, Ahamed *et al.* [5] propusieron arquitecturas personalizadas con mecanismos de atención suave (SPCNN). Validando su modelo con métricas de alta sensibilidad (99,37%) y precisión (99,38%), su trabajo resalta no solo por los resultados numéricos (AUC de 99,95%), sino por la incorporación de mapas de activación que permiten interpretar qué regiones de la célula fueron determinantes para la clasificación. Este panorama confirma que el uso de CNNs bajo esquemas de validación rigurosos permite alcanzar niveles de desempeño que superan la inspección manual.

- “Image-based detection and classification of malaria parasites and leukocytes with quality assessment of romanowsky-stained blood smears,” *Sensors*, vol. 25, no. 2, p. 390, 2025.
- [2] A. M. Rojas Tocora, “Clasificación de parásitos de la malaria,” 2024.
- [3] P. S. Segovia, L. O. Cedeño, and L. Z. Gómez, “Diagnóstico de malaria mediante el uso de redes neuronales convolucionales,” 2021.
- [4] A. Jain, “Malaria cell images dataset,” <https://www.kaggle.com/datasets/iarunava/cell-images-for-detecting-malaria>, 2018.
- [5] M. F. Ahamed, M. Nahiduzzaman, G. Mahmud, F. B. Shafi, M. A. Ayari, A. Khandakar, M. Abdullah-Al-Wadud, and S. R. Islam, “Improving malaria diagnosis through interpretable customized cnns architectures,” *Scientific reports*, vol. 15, no. 1, p. 6484, 2025.
- [6] W. Siłka, M. Wiecek, J. Siłka, and M. Woźniak, “Malaria detection using advanced deep learning architecture,” *Sensors*, vol. 23, no. 3, p. 1501, 2023.
- [7] A. M. Bautista, L. E. N. Vargas, and E. M. Vilca, “Comparativa de modelos basados en redes neuronales convolucionales: Resnet-50v2, mobilenetv2 e efficientnetb0 en la detección de malaria,” *Micaela Revista de Investigación-UNAMBA*, vol. 5, no. 1, pp. 42–49, 2024.
- [8] S. Rajaraman, S. K. Antani, M. Poostchi, K. Silamut, M. A. Hossain, R. J. Maude, S. Jaeger, and G. R. Thoma, “Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images,” *PeerJ*, vol. 6, p. e4568, 2018.
- [9] A. Ferreras Extremo *et al.*, “Estudio de algoritmos de redes neuronales convolucionales en dataset de imágenes médicas,” 2021.

REFERENCES

- [1] J. Sora-Cardenas, W. M. Fong-Amaris, C. A. Salazar-Centeno, A. Castañeda, O. D. Martínez-Bernal, D. R. Suárez, and C. Martínez,